

UNIVERSIDAD DEL VALLE DE GUATEMALA



Proyecto 2 Fase 1

Diego Castillo 25779

Edgar Guevara 251154

Héctor Duarte 25939

REPOSITORIO

<https://github.com/Castle-bot1/Perfessence.git>

Catedrático:

Ing. Sebastián Arriola

Algoritmos y Estructura de Datos

Sección 30

Algoritmos de Recomendación que utilizan bases de datos basadas en grafos

Los sistemas de recomendación son herramientas utilizadas por plataformas como Netflix o Amazon para sugerir opciones personalizadas a los usuarios. Su objetivo es analizar gustos, preferencias y comportamientos para facilitar la toma de decisiones. En este proyecto, se busca aplicar este concepto al contexto de perfumes, ayudando a las personas a encontrar fragancias que realmente se adapten a sus gustos .

El algoritmo PageRank, originalmente desarrollado por Google para clasificar páginas web, ha sido adaptado a sistemas de recomendación. En este contexto, los usuarios y los ítems se representan como nodos dentro de un grafo, y las interacciones entre ellos forman las conexiones. El algoritmo simula un recorrido aleatorio a través del grafo, asignando mayor importancia a los nodos que reciben más visitas o que están conectados con otros nodos relevantes. Esto permite identificar ítems populares o influyentes que pueden ser recomendados a los usuarios. Aunque es un método relativamente simple y eficiente, su principal limitación es que no captura de manera profunda las preferencias individuales, ya que no incorpora aprendizaje automático.

Las Graph Neural Networks (GNN) representan un avance significativo al aplicar técnicas de aprendizaje profundo directamente sobre estructuras de grafos. Estas redes permiten que cada nodo aprenda una representación basada no solo en sus propias características, sino también en la información de sus vecinos. Este proceso, conocido como propagación de mensajes, permite capturar relaciones complejas y dependencias de alto nivel entre usuarios e ítems. Las GNN se utilizan ampliamente en sistemas de recomendación personalizados, así como en redes sociales y detección de fraudes. Sin embargo, su implementación es más compleja y requiere mayores recursos computacionales.

Graph SAGE es una variante de las GNN diseñada para mejorar la escalabilidad en grafos de gran tamaño. En lugar de utilizar todos los vecinos de un nodo, este algoritmo selecciona una muestra de ellos y agrega su información mediante funciones específicas como promedios o mecanismos más avanzados. Esto permite generar representaciones eficientes incluso cuando el grafo es muy grande o dinámico. Una de sus principales ventajas es que puede generalizar a nodos que no estaban presentes durante el entrenamiento, lo cual es útil en aplicaciones donde constantemente se agregan nuevos usuarios o ítems. No obstante, el proceso de muestreo puede ocasionar pérdida de información relevante.

LightGCN es una versión simplificada de las redes neuronales en grafos, diseñada específicamente para sistemas de recomendación. A diferencia de otros modelos más complejos, elimina transformaciones innecesarias y se enfoca únicamente en la propagación de información entre nodos. Esto permite reducir significativamente la complejidad del modelo y mejorar su eficiencia, manteniendo o incluso superando el rendimiento en tareas de recomendación. Este enfoque ha demostrado ser especialmente efectivo en escenarios como

comercio electrónico o plataformas de contenido digital. Su principal desventaja es que, al ser más simple, puede resultar menos flexible para otros tipos de problemas.

Finalmente, PinSage es un algoritmo desarrollado por Pinterest para manejar recomendaciones a gran escala. Este modelo combina ideas de las GNN con técnicas de muestreo basadas en recorridos aleatorios, similares a los utilizados en PageRank. PinSage permite procesar grafos con millones de nodos de manera eficiente, generando representaciones de alta calidad para los ítems. Es particularmente útil en plataformas con grandes volúmenes de datos y alta interacción de usuarios. Sin embargo, su implementación es compleja y requiere infraestructura robusta.

En conclusión, los algoritmos basados en grafos ofrecen una forma poderosa de modelar relaciones en sistemas de recomendación. Desde enfoques más simples como PageRank hasta modelos avanzados como GNN, GraphSAGE, LightGCN y PinSage, cada uno presenta diferentes niveles de complejidad, escalabilidad y precisión. La elección del algoritmo depende del contexto del problema, el tamaño de los datos y los recursos disponibles, pero en general estos métodos permiten lograr recomendaciones más precisas y personalizadas en comparación con enfoques tradicionales.

DESIGN THINKING

Etapas 1: Empatía

Metodología

Se realizaron 5 entrevistas a usuarios reales con distintos perfiles y hábitos de compra, llevadas a cabo por los 3 integrantes del equipo. El objetivo fue comprender las frustraciones, motivaciones y comportamientos reales al momento de elegir un perfume.

Preguntas de la Entrevista:

- ¿Con qué frecuencia compras perfumes?
- ¿Cómo decides qué perfume comprar cuando estás en la tienda?
- ¿Alguna vez compraste un perfume y luego te arrepentiste? ¿Qué pasó?
- ¿Conoces las familias olfativas? (cítrico, amaderado, floral, dulce...)
- ¿El vendedor te ha ayudado a elegir? ¿Fue útil esa ayuda?
- ¿Cuánto tiempo tardas normalmente en decidirte por un perfume?
- ¿Usarías una app o sistema que te recomiende perfumes según tus gustos?

PERFILES DE LOS ENTREVISTADOS

- Alan
- Esther
- Fernanda
- Hugo
- Michelle

Hallazgos por pregunta

¿Con qué frecuencia compras perfumes?

La frecuencia varía bastante entre usuarios. Alan compra 2 a 3 veces al año, Esther cada 2 a 3 meses por gusto a variar, Fernanda cuando se le acaba, Hugo y Michelle cada 6 meses aproximadamente.

¿Cómo deciden qué perfume comprar?

Los criterios son muy distintos entre sí: Alan evalúa la evolución del aroma con el tiempo, Esther se guía por primera impresión y empaque, Fernanda por precio y aroma, Hugo por exclusividad y ediciones limitadas, Michelle considera que su pH resalta el olor.

¿Se han arrepentido de una compra?

3 de 5 usuarios respondieron que sí. Alan compró uno que con el tiempo se volvió demasiado dulce, Esther compró uno por impulso que terminó regalando, Fernanda eligió uno que en casa ya no le agradó. Hugo y Michelle nunca se han arrepentido, pero ambos se toman bastante tiempo para decidir

¿Conocen las familias olfativas?

4 de 5 usuarios dicen conocerlas. Sin embargo, Esther admite no manejarlas bien, solo sabe que le gustan las dulces y florales. Esto indica que el conocimiento es superficial en varios casos.

¿El vendedor ha sido útil?

La experiencia es muy inconsistente. Alan señala que algunos vendedores ayudan genuinamente pero otros solo quieren vender rápido. Hugo directamente prefiere la opinión de su novia al vendedor. Michelle tuvo una experiencia muy positiva con una vendedora que la acompañó todo el proceso. Fernanda rara vez recibe ayuda útil.

¿Cuánto tiempo tardan en decidirse


Aquí hay una diferencia enorme entre usuarios: Esther tarda 10-15 minutos, Fernanda 5-10 minutos, Alan 20-30 minutos, Hugo entre 1 y 1.5 horas, Michelle hasta 3 horas. Esto confirma que la decisión es compleja y variable.

¿Usarían un sistema de recomendación?

Los 5 usuarios respondieron que sí. Alan valora ahorrar tiempo, Esther quiere opciones personalizadas con opiniones de otros usuarios, Fernanda lo ve como una gran idea, Hugo quiere que incluya recomendaciones de otros usuarios, Michelle lo usaría especialmente por ser diseñado por su hermano.

Mapa de Empatía General

Mapa de *Empatía*



Insights importantes de la Etapa 1

- La decisión es emocionalmente compleja. Elegir un perfume no es solo una compra, es una decisión de identidad. Esther regaló uno porque "no era ella". Esto significa que el sistema debe recomendar basado en personalidad y ocasión, no solo en aromas.
- El conocimiento técnico es superficial. La mayoría conoce las familias olfativas de nombre pero no sabe aplicarlas para tomar decisiones. El sistema debe traducir ese conocimiento técnico en algo accesible.
- La ayuda actual es inconsistente y poco confiable. Los vendedores a veces ayudan, a veces no. No hay un estándar. Un sistema de recomendación ofrece consistencia que el factor humano no garantiza.

Etapa 2: Definición

Point of View (POV) Declaración del problema

Los compradores de perfumes necesitan una forma confiable y personalizada de descubrir fragancias que realmente se adapten a su personalidad, ocasión y tipo de piel, porque

actualmente toman decisiones basadas en impulsos, tendencias o recomendaciones inconsistentes de vendedores, lo que frecuentemente resulta en compras insatisfactorias.

How Might We (HMW) ¿Cómo Podríamos?

- ¿Cómo podríamos ayudar al usuario a identificar su familia olfativa favorita sin necesidad de conocimiento técnico previo?
- ¿Cómo podríamos reducir el tiempo de decisión sin sacrificar la satisfacción del usuario?
- ¿Cómo podríamos replicar la experiencia de un vendedor experto de forma consistente y personalizada?
- ¿Cómo podríamos aprovechar las experiencias de otros compradores con gustos similares para hacer mejores recomendaciones?
- ¿Cómo podríamos considerar factores como el pH de la piel o la ocasión de uso dentro de una recomendación?

Definición del usuario objetivo

Persona 1 “El Indeciso”: Representado por Alan y Hugo. Conoce algo sobre perfumes, se toma su tiempo (30 min a 1.5 horas), evalúa con cuidado pero aun así puede terminar insatisfecho porque le faltan herramientas objetivas para comparar opciones.

Persona 2 “La Compradora Impulsiva”: Representada por Esther y Fernanda. Decide rápido (5 a 15 minutos), se guía por emoción o primera impresión, y tiene mayor probabilidad de arrepentirse porque no conecta sus gustos reales con la compra.

Declaración Formal del Problema

El proceso de selección de perfumes en perfumerías como Fetiche carece de personalización real. Los usuarios no cuentan con herramientas que traduzcan sus preferencias personales, su tipo de piel y la ocasión de uso en recomendaciones concretas y confiables. Esto genera decisiones impulsivas, compras insatisfactorias y una experiencia de compra frustrante, especialmente para quienes no dominan el lenguaje técnico de las familias olfativas.

Etapas 3: Ideación

Posibles soluciones a través de ideas

1. Quiz de preferencias olfativas. Un cuestionario inicial donde el usuario responde preguntas sobre sus gustos, personalidad y ocasión de uso. El sistema traduce esas respuestas en una familia olfativa recomendada.
2. Motor de recomendación colaborativo. Un sistema que analiza los ratings y preferencias de usuarios con gustos similares para sugerir perfumes. Si a alguien con tu mismo perfil le encantó cierto perfume, el sistema te lo recomienda.

3. Buscador por características. El usuario filtra perfumes por atributos específicos: familia olfativa, intensidad, ocasión, precio, género. El sistema muestra opciones que cumplan esos criterios.
4. Recomendación por perfume favorito. El usuario ingresa un perfume que ya le gusta y el sistema encuentra otros con características similares basándose en sus atributos.
5. Perfil de usuario con historial. El sistema aprende con el tiempo de las compras y ratings del usuario, mejorando sus recomendaciones a medida que acumula más datos.
6. Recomendación por ocasión. El usuario indica para qué ocasión necesita el perfume (trabajo, noche, deporte, cita) y el sistema filtra opciones adecuadas para ese contexto.

Idea Seleccionada: Sistema Híbrido

Un motor de recomendación híbrido que combina un quiz de preferencias inicial para usuarios nuevos, con filtrado colaborativo basado en usuarios similares y filtrado por contenido basado en los atributos del perfume.


¿Por qué esta idea y no las otras?

IDEA	VENTAJA	LIMITACIÓN
Solo quiz	Fácil de usar	No aprende, ni mejora.
Solo colaborativo	Muy personalizado	No funciona con usuarios nuevos.
Solo por características	Muy específico	No descubre opciones nuevas.
HÍBRIDO	Funciona desde el inicio y mejora con el tiempo	Requiere más desarrollo.

Conexión con los usuarios entrevistados

- Quiz inicial: responde a Esther y Fernanda que no manejan bien las familias olfativas
- Filtrado colaborativo: responde a Esther que quería opiniones de otras personas.
- Filtrado por contenido: responde a Alan que evalúa cómo evoluciona el aroma
- Recomendación por ocasión: responde a Michelle que usa distintos perfumes según el momento.

Etapa 4: Prototipos de Baja Fidelidad





Etapas 5: Testing

Metodología

Se presentaron los prototipos de baja fidelidad a los mismos usuarios entrevistados en la etapa de Empatía y a algunos otros usuarios extras. Se les mostró el flujo completo de pantallas y se les hicieron las siguientes preguntas para validar la solución.

Conclusiones del Testing

Los 5 usuarios comprendieron el sistema de forma inmediata sin necesidad de explicación adicional, lo que valida que el flujo de pantallas es intuitivo y claro. La funcionalidad más valorada fue el porcentaje de compatibilidad y las recomendaciones basadas en usuarios similares, lo que confirma que el enfoque de filtrado colaborativo responde a una necesidad real.

Las sugerencias más recurrentes fueron agregar un filtro de precio y la posibilidad de guardar perfumes favoritos, ambas funcionalidades que el equipo considerará para fases futuras del desarrollo.

En general, el prototipo fue bien recibido y los usuarios expresaron una alta disposición a utilizar el sistema, lo que demuestra que la solución propuesta es relevante y tiene potencial real en el contexto de perfumerías como Fetiche.

Pseudocódigo

INICIO

```
// =====  
// PASO 1: RECIBIR AL USUARIO  
// =====
```

RECIBIR usuario

SI usuario es nuevo ENTONCES

 MOSTRAR quiz de preferencias

 RECIBIR respuestas del quiz

 CREAR perfil del usuario con:

 - familia olfativa favorita

 - intensidad preferida

 - ocasión de uso

 - presupuesto

 GUARDAR perfil en base de datos

FIN SI

```
// =====  
// PASO 2: BUSCAR USUARIOS SIMILARES  
// =====
```

```
PARA CADA usuario_existente EN base_de_datos HACER
    similitud = CALCULAR similitud coseno(usuario, usuario_existente)
    GUARDAR similitud en lista_similitudes
FIN PARA
```

```
ORDENAR lista_similitudes de mayor a menor
usuarios_similares = TOMAR los 5 primeros de lista_similitudes
```

```
// =====
// PASO 3: RECOPIRAR PERFUMES CANDIDATOS
// =====
```

```
PARA CADA usuario_similar EN usuarios_similares HACER
    AGREGAR sus perfumes mejor calificados a lista_candidatos
FIN PARA
```

```
// Eliminar perfumes que el usuario ya conoce
PARA CADA perfume EN lista_candidatos HACER
    SI perfume YA FUE visto por usuario ENTONCES
        ELIMINAR perfume de lista_candidatos
    FIN SI
FIN PARA
```

```
// =====
// PASO 4: CALCULAR SCORE FINAL
// =====
```

```
PARA CADA perfume EN lista_candidatos HACER
```

```
    score_colaborativo = promedio de ratings de usuarios_similares
    score_contenido = similitud coseno(perfil_usuario, atributos_perfume)
```

```
    SI usuario tiene historial ENTONCES
```

```
        alpha = 0.7
```

```
    SINO
```

```
        alpha = 0.3
```

```
    FIN SI
```

```
     $score\_final = (alpha \times score\_colaborativo) + ((1 - alpha) \times score\_contenido)$ 
```

```
    GUARDAR score_final del perfume
```

```
FIN PARA
```

```
// =====
// PASO 5: MOSTRAR RECOMENDACIONES
// =====

ORDENAR lista_candidatos por score_final de mayor a menor
recomendaciones = TOMAR los 5 primeros
MOSTRAR recomendaciones al usuario

// =====
// PASO 6: RECIBIR FEEDBACK
// =====

SI usuario califica un perfume ENTONCES
  GUARDAR calificacion en base_de_datos
  ACTUALIZAR perfil del usuario
FIN SI

FIN
```

Base de Datos en Neo4j

La base de datos fue modelada como grafo, donde se representan las entidades principales del sistema. Los nodos principales incluyen las categorías de Usuarios (en este caso incluyen a los entrevistados que tenemos sus datos, y en estos nodos se almacenan información relevante como preferencias que vinculan a los otros), Perfumes (estos son ejemplares encontrados en bases de datos, e incluyen datos como nombre, intensidad y precio), Familias Olfativas y Ocasiones.

Las relaciones nos permiten conectar estos nodos y modelar el comportamiento del sistema. Los perfumes estan conectados a sus características mediante relaciones como PERTENECE_A (familia olfativa) y IDEAL_PARA (ocasión),

El grafo, como puede verse, se puede ver como múltiples vértices conectados los cuales representan los usuarios y perfumes relacionados por preferencias en común (aunque de momento pueden parecer datos dispersos) conforme que se agreguen mas interacciones los componentes se volveran mas densos y asi permitir generar recomendaciones mas precisas mediante la propagación de similitud dentro del grafo.

The screenshot shows the Neo4j Aura web interface. The top navigation bar includes links for 'Get started', 'Developer hub', 'Data services', 'Instances', 'Graph Analytics', 'GraphQL Data APIs', 'Agents', 'Tools', 'Import', 'Query', 'Explore', 'Dashboards', 'Operations', 'Project', and 'Learning'. The main content area is divided into several sections:

- Database information:** Shows the current database as 'perfumessence' and the user as 'Aura (hdulam24@gmail.com)'. It lists nodes (0) and relationships (0) with various property keys like 'familia_preferida', 'intensidad', 'nombre', 'ocasion_preferida', 'precio', 'presupuesto', 'rating', and 'tipo'.
- Graph:** A visual representation of the data as a network of nodes and edges. Nodes are colored (blue, green, orange) and connected by lines representing relationships.
- Results overview:** Displays the results of the query. It shows 17 nodes and 13 relationships. The results are summarized as follows:
 - Nodes (17): 4 Familia, 3 Ocasión, 5 Perfume, 5 Usuario.
 - Relationships (13): 3 IDEAL_PARA, 5 PERTENECE_A, 5 RATED.

The bottom of the interface shows the query execution details: 'Started streaming 13 records after 17 ms and completed after 18 ms'.

Esto se generó usando el comando: `MATCH (n)-[r]->(m) RETURN n, r, m;`



